Tema 2 - Inteligenta Artificiala

Clasificarea Imaginilor cu Retele Neurale

Seturi de date: "Vai de pielea mea" & "You're on candid camera"

Introducere

Tema 2 are ca obiectiv antrenarea si evaluarea retelelor neurale pentru clasificarea imaginilor, folosind doua seturi de date distincte. Am implementat mai multe tipuri de arhitecturi (MLP, CNN, fine-tuning pe retele pre-antrenate) si am analizat impactul diferitelor tehnici de antrenare prin ablatii sistematice.

Setul de date "Vai de pielea mea" — leziuni cutanate

Contine 10.015 imagini dermatoscopice color (130x100 px) ale leziunilor cutanate pigmentate, impartite in 7 clase diagnostice:
- akiec: Bowel disease
- bcc: Carcinom bazocelular
- bkl: Leziuni benigne de tip keratoza
- df: Dermatofibrom
- mel: Melanom
- nv: Nevi melanocitari (alunite obisnuite)
- vasc: Leziuni vasculare

Setul este puternic dezechilibrat — clasa nv reprezinta ~67% din date, in timp ce df si vasc sunt sub 1%. Split: 6.009 train / 2.003 test / 2.003 kaggle_test.

Setul de date "You're on candid camera" — expresii faciale

Contine 15.339 imagini color (100x100 px) cu expresii faciale colectate in conditii reale si necontrolate, impartite in 7 clase de emotii:
- 1: Surprise (10.5%)
- 2: Fear (2.3%)
- 3: Disgust (5.8%)
- 4: Happiness (38.9%)
- 5: Sadness (16.1%)
- 6: Anger (5.8%)
- 7: Neutral (20.6%)

Si acest set e dezechilibrat — Happiness domina cu ~39%, Fear e cel mai rar cu doar 2.3%. Split: 10.434 train / 1.837 local test / 3.068 remote test (Kaggle).

Modele antrenate

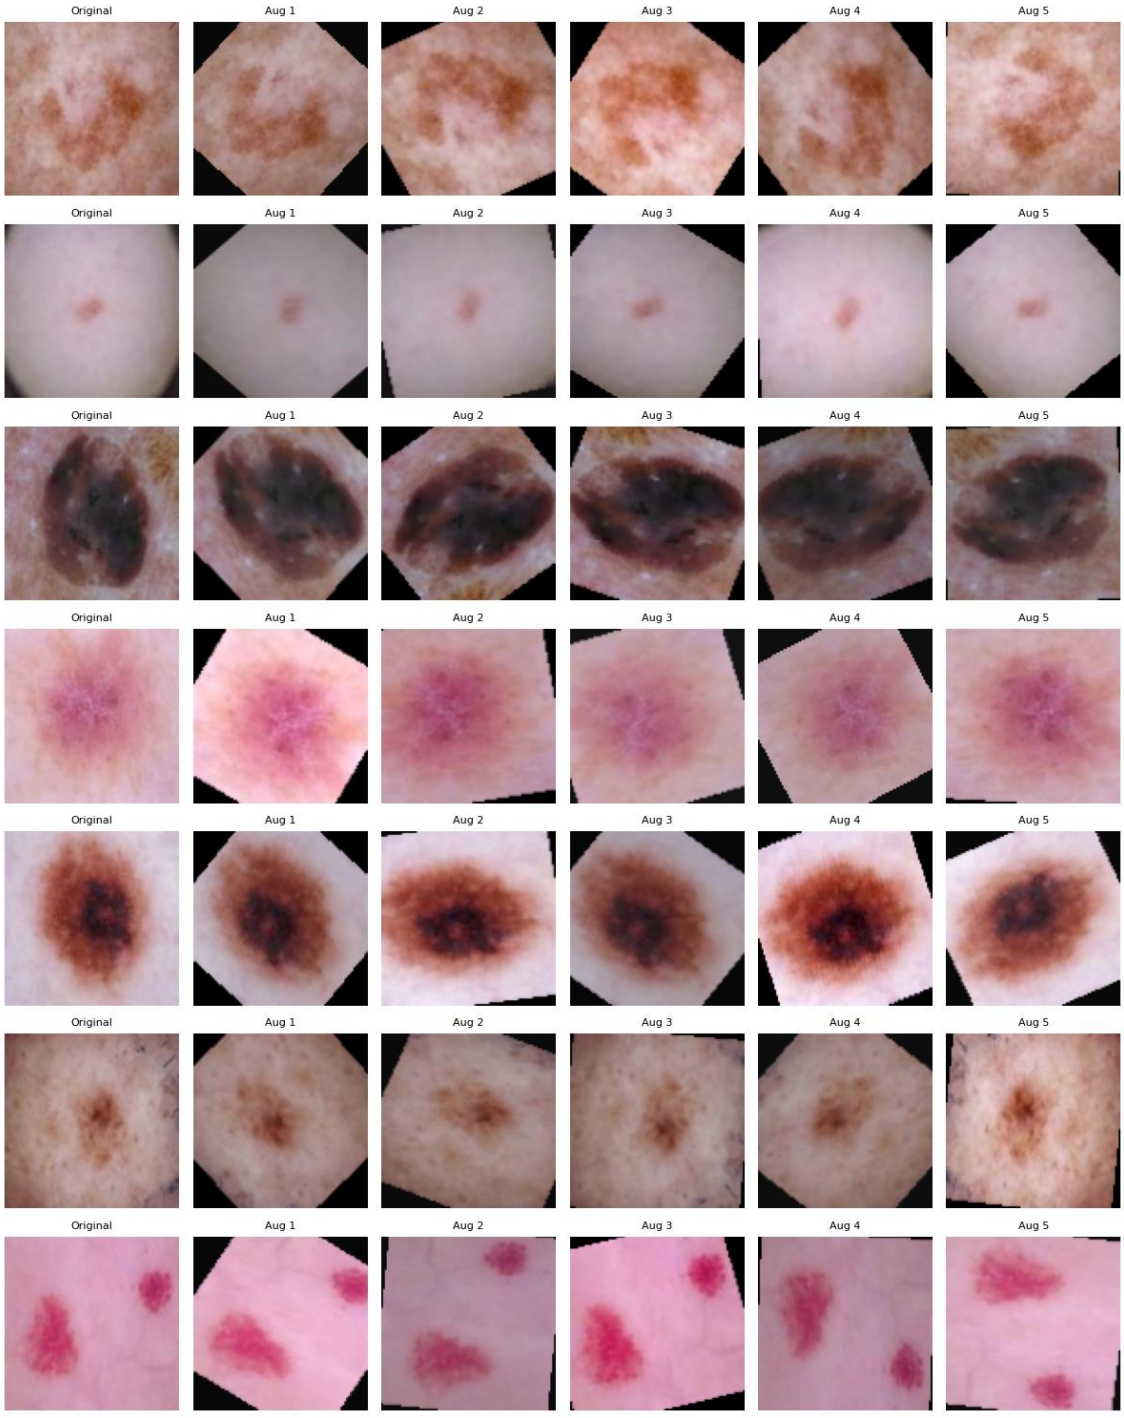
Pentru fiecare set de date am antrenat:
- MLP (Multi-Layer Perceptron): retea fully-connected, imagini aplatizate ca vector
- CNN (Convolutional Neural Network): arhitectura convolutionala cu max 4 conv + 2 linear
- ResNet-18: retea pre-antrenata pe ImageNet, full fine-tuning cu LR diferentiat
- MobileNet-v2: retea pre-antrenata pe ImageNet, full fine-tuning cu LR diferentiat

In plus, am realizat ablatii pentru: dropout (MLP), BatchNorm (CNN), configuratii de augmentare (CNN), dezechilibru de clase si LR warmup (fine-tuning).

Vizualizarea Augmentarilor

"Vai de pielea mea" - Augmentari

Pentru setul de leziuni cutanate am ales urmatoarele augmentari:
- RandomHorizontalFlip + RandomVerticalFlip (p=0.5): leziunile nu au o orientare naturala asa ca flip-urile sunt valide din punct de vedere medical.
- RandomRotation(180): din acelasi motiv, orice unghi de rotatie e ok.
- RandomResizedCrop(96, scale=0.85-1.0): simulam distante usor diferite fata de leziune.
- ColorJitter subtil (brightness=0.15, contrast=0.15): iluminarea variaza la dermatoscopie, dar am pastrat valorile mici ca sa nu alterez culorile diagnostice ale melanomului.

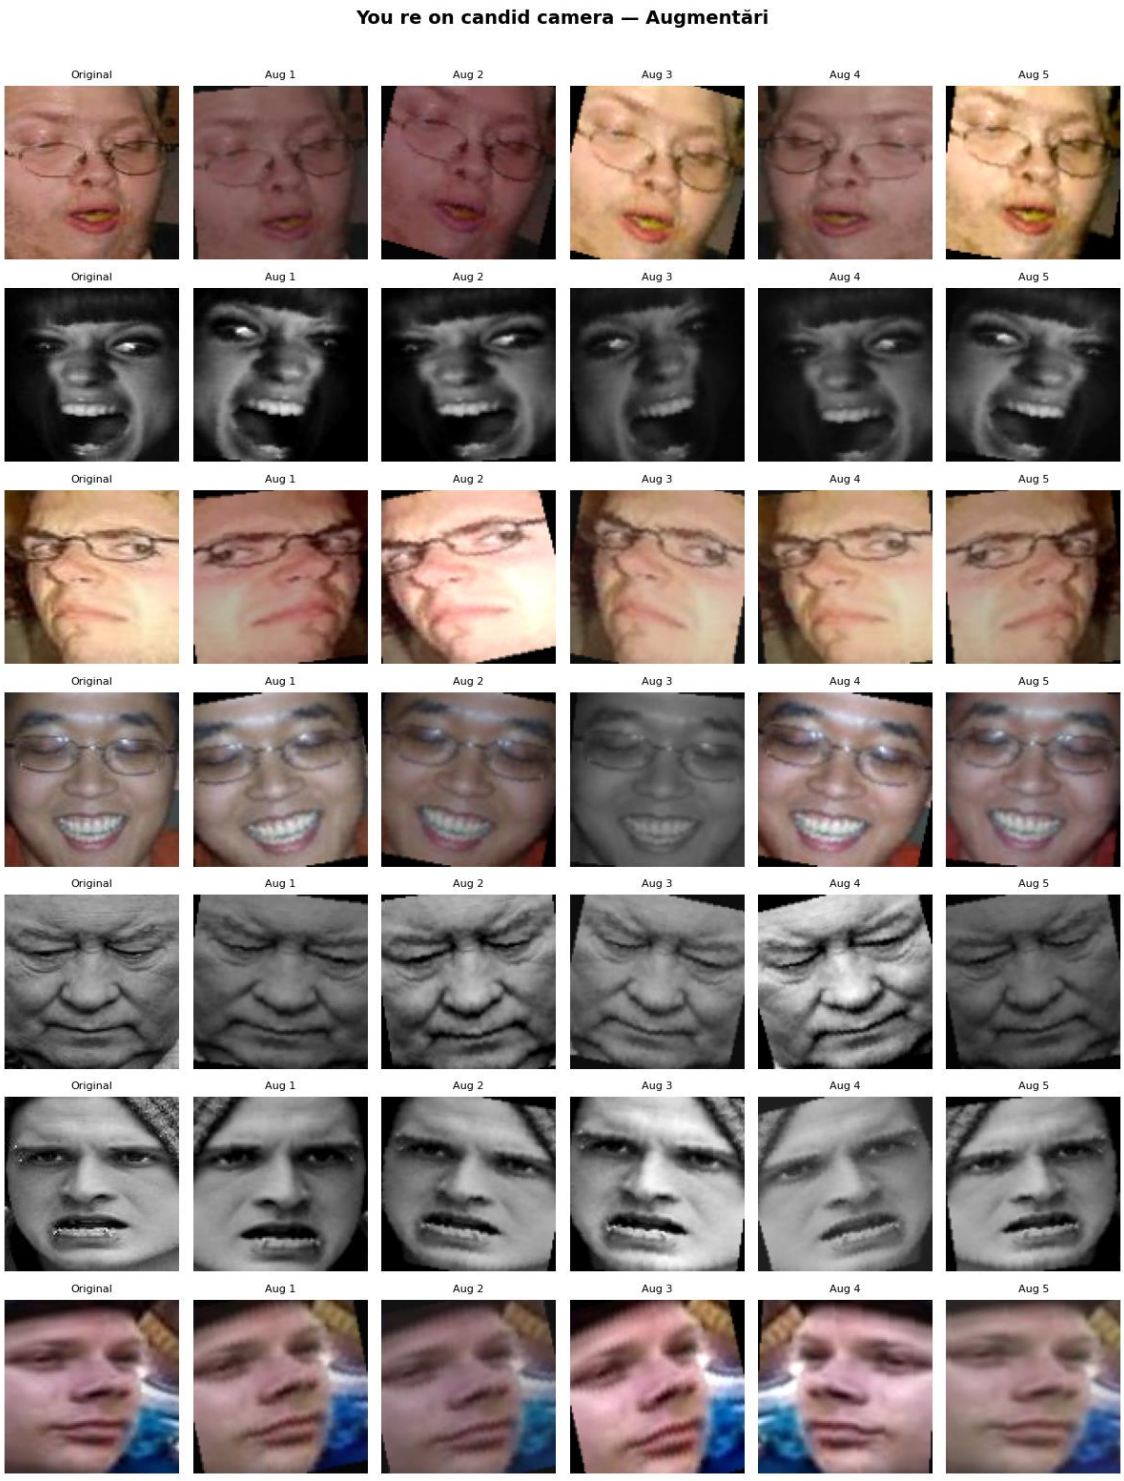


"You're on candid camera" - Augmentari

Pentru expresiile faciale am ales:

- RandomHorizontalFlip (p=0.5): fetele pot aparea simetric.
- RandomVerticalFlip: NU am aplicat - o fata cu capul in jos nu are sens.
- RandomRotation(15): inclinarea usoara a capului e frecventa in realitate.

- ColorJitter moderat (brightness=0.3, contrast=0.3): iluminarea variaza mult in conditii reale.
- RandomGrayscale(p=0.05): robustete fata de imagini alb-negru.
- RandomResizedCrop(100, scale=0.85-1.0): pozitionarea fetei variaza usor in cadru.



Arhitectura MLP

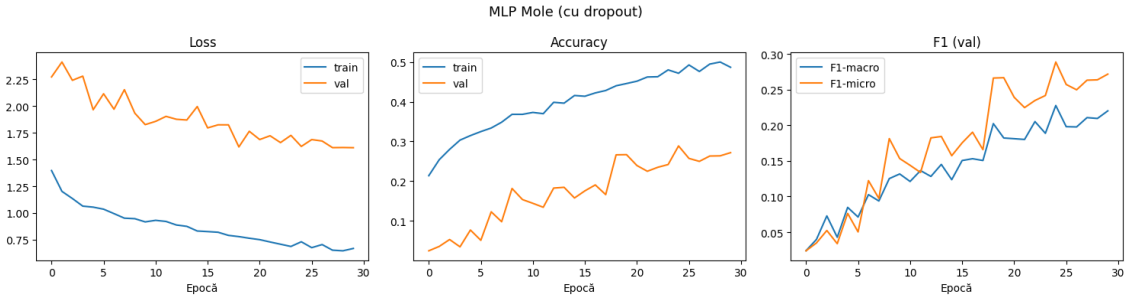
Am folosit aceeasi arhitectura MLP pentru ambele seturi, diferenta fiind doar dimensiunea de intrare (96x96x3=27648 pentru Mole, 100x100x3=30000 pentru Face).

Arhitectura:
Flatten -> Linear(in, 1024) -> BN1d -> ReLU -> Dropout(0.4)
-> Linear(1024, 512) -> BN1d -> ReLU -> Dropout(0.3)
-> Linear(512, 256) -> BN1d -> ReLU -> Dropout(0.2)
-> Linear(256, 7)

Am ales 3 straturi ascunse deoarece ofera suficienta capacitate pentru imagini mici. Dropout-ul descrescator (0.4->0.3->0.2) previne overfitting-ul. BatchNorm1d stabilizeaza antrenarea si permite learning rate mai mare.

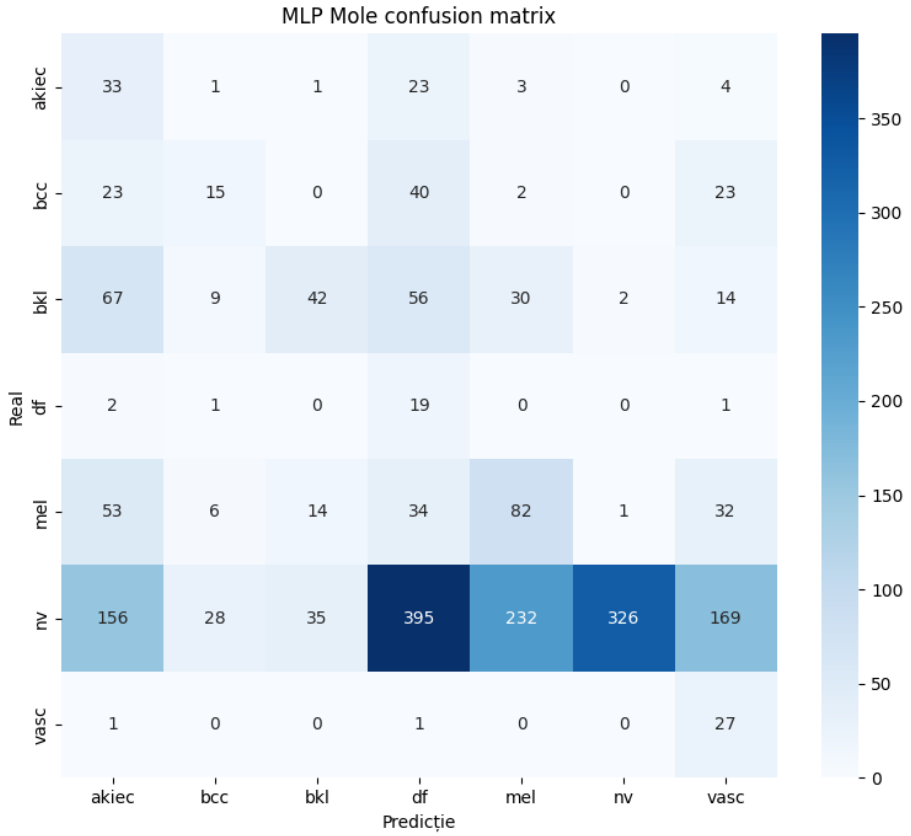
Antrenare: Adam (lr=1e-3, weight_decay=1e-4), CosineAnnealingLR, 30 epoci, WeightedRandomSampler + CrossEntropyLoss ponderat pentru dezechilibru.

Curbe antrenare MLP - Mole



Graficul are trei panouri: Loss, Accuracy si F1 (val), toate in functie de epoca. Pe panoul de Loss se vede clar ca train loss scade constant de la ~1.4 spre ~0.65, in timp ce val loss ramane mult mai sus, in jur de 1.6-1.7 la final. Distanta mare dintre cele doua curbe imi spune ca modelul incepe sa memoreze setul de train (overfitting), ceea ce e de asteptat pentru un MLP care vede pixelii aplatizati, fara nicio notiune de vecinatate spatiala. Pe panoul de Accuracy, train acc urca pana la ~0.49, dar val acc se opreste in jur de 0.27, deci diferenta de generalizare e vizibila si aici. Panoul din dreapta arata F1-macro si F1-micro pe validare: ambele cresc zgomotos de la ~0.03 la ~0.22 (macro), respectiv ~0.27 (micro). Faptul ca F1-micro > F1-macro confirma ca modelul se descurca mai bine pe clasele frecvente (nv) decat pe cele rare, exact ce ma asteptam pe un set atat de dezechilibrat. Best val F1-macro pentru aceasta rulare a fost 0.2276.

Matricea de confuzie MLP - Mole

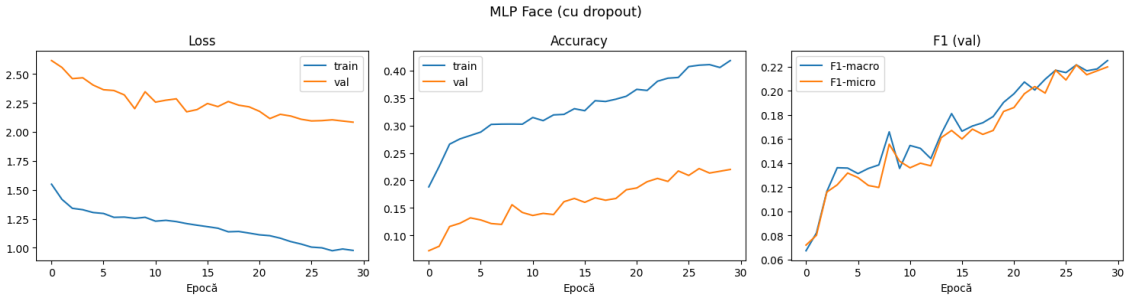


Matricea de confuzie are pe verticala clasa reala si pe orizontala predictia, iar intensitatea albastra creste cu numarul de exemple. Cel mai vizibil lucru este randul lui nv, care e clasa majoritara: modelul imprastie predictiile pe acest rand peste tot (akiec, df, mel, nv, vasc), adica multe alunite obisnuite sunt clasificate gresit ca alte tipuri de leziuni. Asta se intampla din cauza WeightedRandomSampler-ului, care forteaza modelul sa vada des clasele rare si in schimb sacrifica precizia pe nv. Diagonala e slaba in general (akiec 33/65, bcc 15/103, df 19/23 dar cu foarte multe false pozitive pe df), semn ca un MLP fara structura spatiala nu prinde bine trasaturile dermatoscopice. In esenta matricea confirma numerele din tabelul de mai jos: recall decent pe cateva clase rare, dar precizie foarte mica peste tot.

Metrici per clasa — MLP Mole (cu dropout)

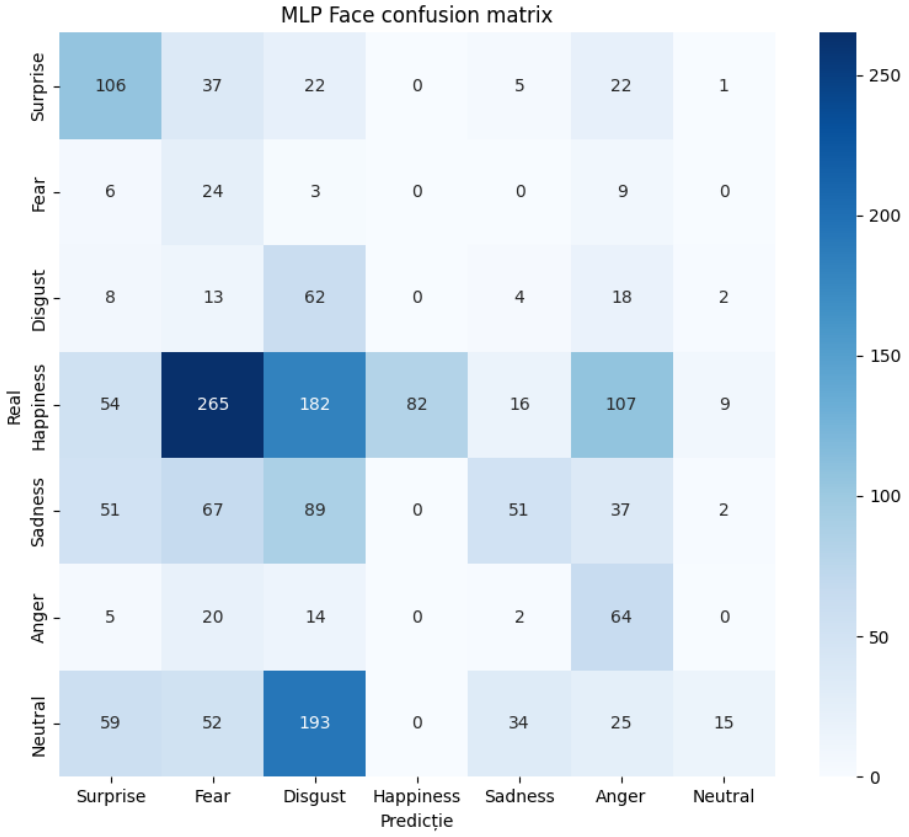
Clasa	Precision	Recall	F1-score	Support
akiec	0.10	0.51	0.17	65
bcc	0.25	0.15	0.18	103
bkl	0.46	0.19	0.27	220
df	0.03	0.83	0.06	23
mel	0.23	0.37	0.29	222
nv	0.99	0.24	0.39	1341
vasc	0.10	0.93	0.18	29

Curbe antrenare MLP - Face



Si aici am cele trei panouri (Loss, Accuracy, F1 val). Train loss coboara de la ~1.6 la ~1.0, in timp ce val loss ramane prinsa pe la 2.1-2.2, deci gap-ul de generalizare e si mai mare decat la Mole. Pe Accuracy, train acc ajunge la ~0.42 dar val acc se opreste pe la 0.22, ceea ce arata acelasi pattern de overfitting. F1-macro pe validare creste lent de la ~0.06 la ~0.22 si e foarte zgomotos, ceea ce e normal cand ai 7 emotii usor de confundat intre ele si un set dezechilibrat (Happiness ~39%, Fear ~2.3%). Convergenta e mai inceata decat pe Mole pentru ca expresiile faciale au variabilitate mult mai mare (iluminare, unghi, ocluzie), iar un MLP care vede doar pixeli aplatizati nu are cum sa modeleze relatiile spatiale dintre ochi, gura si sprancene. Best val F1-macro: 0.2252.

Matricea de confuzie MLP - Face



In matrice se vede imediat problema clasei Happiness: desi e clasa majoritara (715 exemple), modelul o prezice corect doar de 82 de ori, iar restul de exemple Happiness se imprastie masiv spre Fear (265), Disgust (182) si Anger (107). Practic samplerul a impins atat de tare clasele rare incat modelul a ajuns sa subprezica clasa cea mai frecventa, de unde si recall-ul minuscul de 0.11 pe Happiness din tabel, desi precizia e 1.00 (cand zice Happiness, chiar e Happiness). Coloana Disgust e foarte aglomerata (multe clase ajung gresit acolo), deci Disgust e o clasa-magnet in care modelul ingramadeste exemplele de care nu e sigur. Diagonala e in general slaba, ceea ce confirma ca un MLP pur nu e potrivit pentru expresii faciale.

Metrici per clasa — MLP Face (cu dropout)

Clasa	Precision	Recall	F1-score	Support
Surprise	0.37	0.55	0.44	193
Fear	0.05	0.57	0.09	42
Disgust	0.11	0.58	0.18	107
Happiness	1.00	0.11	0.21	715
Sadness	0.46	0.17	0.25	297
Anger	0.23	0.61	0.33	105
Neutral	0.52	0.04	0.07	378

Ablatie MLP: cu vs. fara Dropout



Graficul compara cele doua variante pe Val Loss (stanga) si Val F1-macro (dreapta), atat pentru Mole cat si pentru Face. Sincer, rezultatul m-a surprins: varianta FARA dropout obtine F1-macro

mai mare pe validare la ambele seturi (pe Mole ajunge la ~0.305 fata de ~0.228 cu dropout, pe Face ~0.310 fata de ~0.225), iar val loss e chiar mai mica fara dropout. Cu alte cuvinte, in acest caz dropout-ul nu a ajutat, ci a incetinit invatarea. Explicatia mea este ca MLP-ul meu e deja puternic regularizat de BatchNorm si de weight_decay, iar pe seturi atat de mici si grele modelul oricum nu apuca sa faca overfit serios in 30 de epoci, asa ca dropout-ul de 0.4/0.3/0.2 doar a redus capacitatea efectiva. Pe curbele de loss diferenta de overfit dintre train si val e similara la ambele variante, deci nu vad un overfitting pe care dropout-ul sa il fi rezolvat. Concluzia onesta a ablatiei: pentru configuratia mea, dropout-ul nu aduce un castig de F1-macro pe validare. Numerele din tabelul sumar sunt raportate totusi pentru varianta cu dropout, asa cum am setat-o ca varianta de baza.

Arhitectura CNN

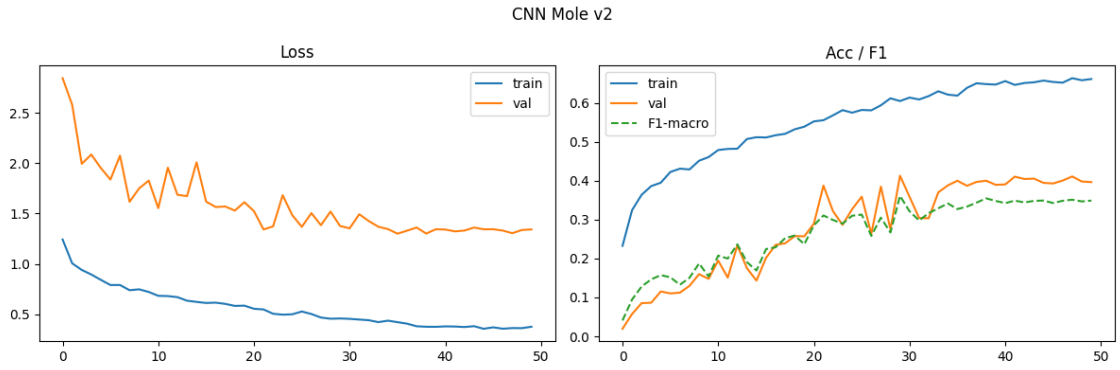
Am implementat o arhitectura CNN comuna ambelor seturi, diferentiata doar la primul kernel:

Block1: Conv(3->32, kxk) -> BN2d -> ReLU -> MaxPool(2)
Block2: Conv(32->64, 3x3) -> BN2d -> ReLU -> MaxPool(2)
Block3: Conv(64->128, 3x3) -> BN2d -> ReLU -> MaxPool(2)
Block4: Conv(128->256, 3x3) -> BN2d -> ReLU
AdaptiveAvgPool2d(1) -> Flatten -> Dropout(0.5) -> Linear(256,128) -> ReLU -> Linear(128,7)

Am ales primul kernel 5x5 pentru Mole (leziunile au feature-uri de scara mai mare: asimetrie, structuri pigmentare) si 3x3 pentru Face (contururi mici: ochi, gura, sprancene).
Am pus bias=False la Conv2d deoarece BatchNorm are deja parametrul beta. AdaptiveAvgPool face reteaua agnostica la rezolutie. Numarul de filtre se dubleaza la fiecare bloc (32->64->128->256), pattern clasic.

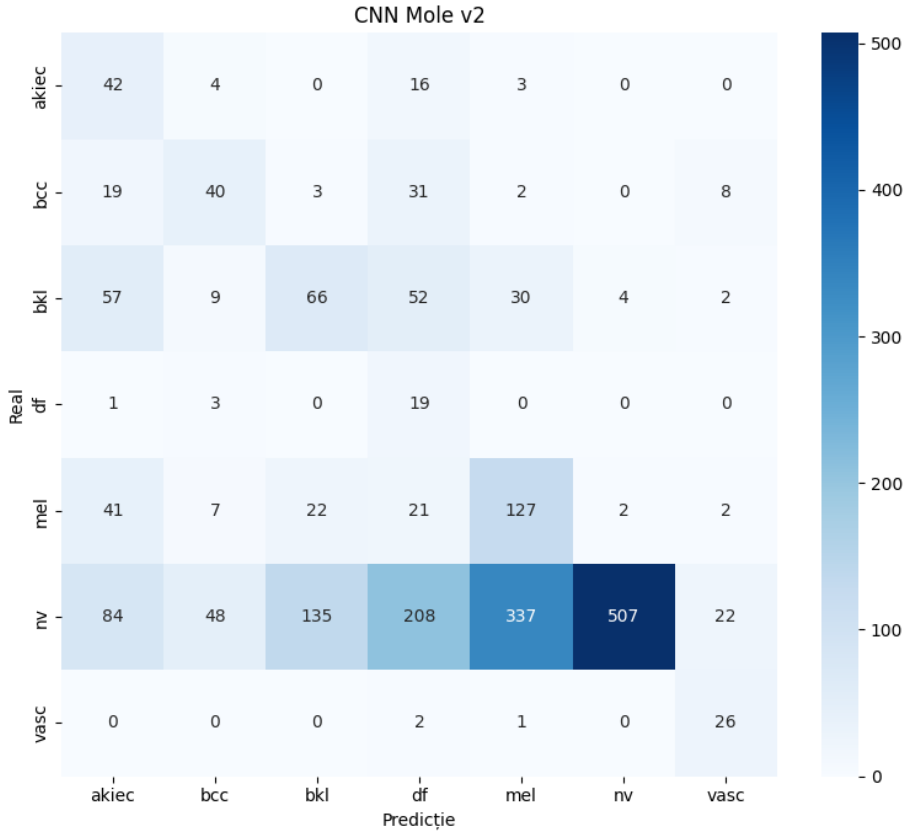
Antrenare: Adam (lr=1e-3, weight_decay=1e-4), CosineAnnealingLR, 50 epoci, WeightedRandomSampler + CrossEntropyLoss ponderat.

Curbe antrenare CNN - Mole



Pe panoul de Loss, train loss coboara frumos spre ~0.35, dar val loss se aseaza pe la 1.3-1.4 si nu mai scade dupa epoca ~30, deci avem un gap clar train/val care indica overfitting moderat (de asteptat pe un set mic). Pe panoul Acc/F1, train acc urca pana spre ~0.65, in timp ce val acc + F1-macro (linia verde intrerupta) se plafoneaza in jur de 0.35-0.40. Faptul ca F1-macro de validare se opreste sub acuratetea de train imi confirma ca CNN-ul invata reprezentari bune dar incepe sa memoreze. Fata de MLP se vede clar saltul: CNN-ul ajunge la F1-macro ~0.36-0.40 fata de ~0.22 la MLP, exact pentru ca straturile convolutionale prind structura spatiala a leziunilor (margini, asimetrie, textura). Augmentarile si BatchNorm-ul tin gap-ul sub control, dar nu il elimina complet.

Matricea de confuzie CNN - Mole

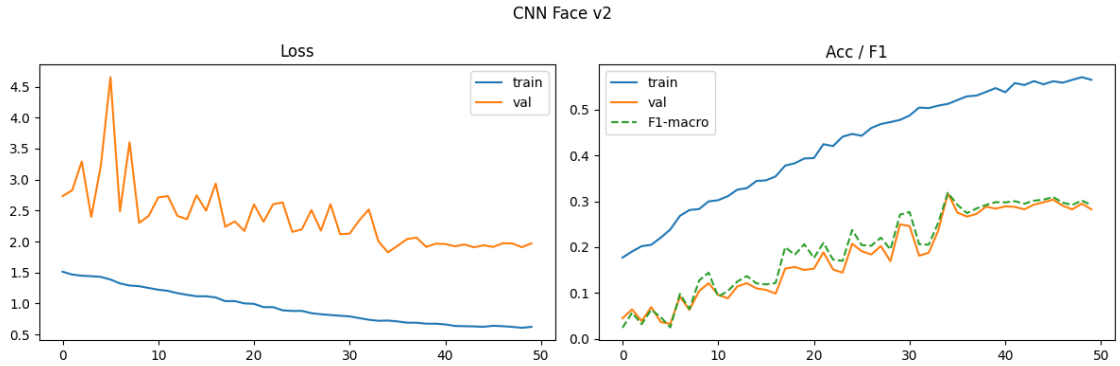


Diagonala e mai puternica decat la MLP (nv 507, mel 127, bkl 66, akiec 42, vasc 26/29), deci CNN-ul chiar invata trasaturi utile. Tot randul lui nv ramane insa imprastiat: 507 corecte dar si 337 confundate cu mel, 208 cu df si 135 cu bkl. Practic modelul confunda cel mai des nevii cu melanomul si cu keratozele, ceea ce e de fapt confuzia clinic dificila si interesanta (nev vs melanom seamana vizual). vasc iese aproape perfect (26/29) pentru ca leziunile vasculare au culoare distincta. bkl e clasa cea mai problematica: se imprastie spre akiec, df si mel. Per total, comparand cu MLP, recall-ul pe nv a urcat de la 0.24 la 0.38 si pe vasc de la 0.93 cu precizie mica la 0.90 cu precizie mai buna, deci convolutiile ajuta clar.

Metrici per clasa — CNN Mole (50 epoci)

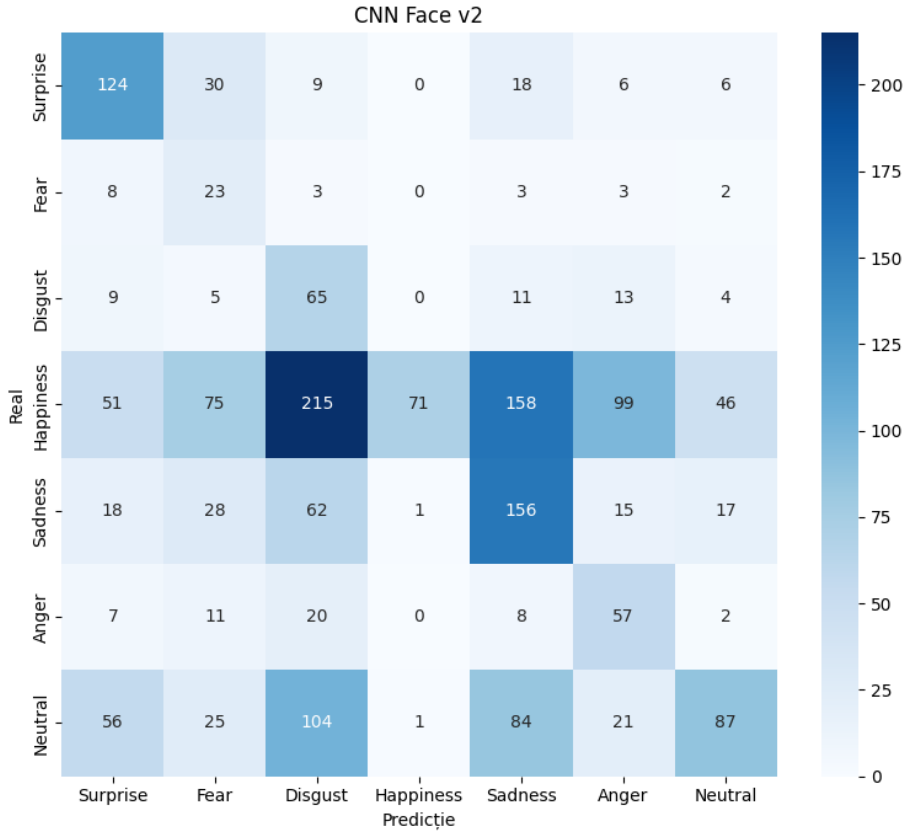
Clasa	Precision	Recall	F1-score	Support
akiec	0.17	0.65	0.27	65
bcc	0.36	0.39	0.37	103
bkl	0.29	0.30	0.30	220
df	0.05	0.83	0.10	23
mel	0.25	0.57	0.35	222
nv	0.99	0.38	0.55	1341
vasc	0.43	0.90	0.58	29

Curbe antrenare CNN - Face



Train loss coboara spre ~0.6 dar val loss ramane prinsa pe la ~1.9-2.0, deci gap-ul train/val e mare, mai mare decat la Mole, fiindca expresiile faciale sunt mult mai variabile. Pe panoul Acc/F1, train acc urca constant peste 0.5, dar val acc si F1-macro (verde intrerupt) se plafoneaza in jur de 0.30-0.32. Curbele de validare sunt destul de zgomotoase, ceea ce reflecta atat dezechilibrul (Happiness 39% vs Fear 2.3%), cat si faptul ca unele emotii se confunda usor intre ele chiar si pentru oameni. Clasa Fear, cu doar 2.3% din date, e cea mai grea de prins, dar pe ansamblu CNN-ul tot bate net MLP-ul (0.32 vs 0.22 F1-macro) tocmai pentru ca prinde geometria locala a fetei.

Matricea de confuzie CNN - Face

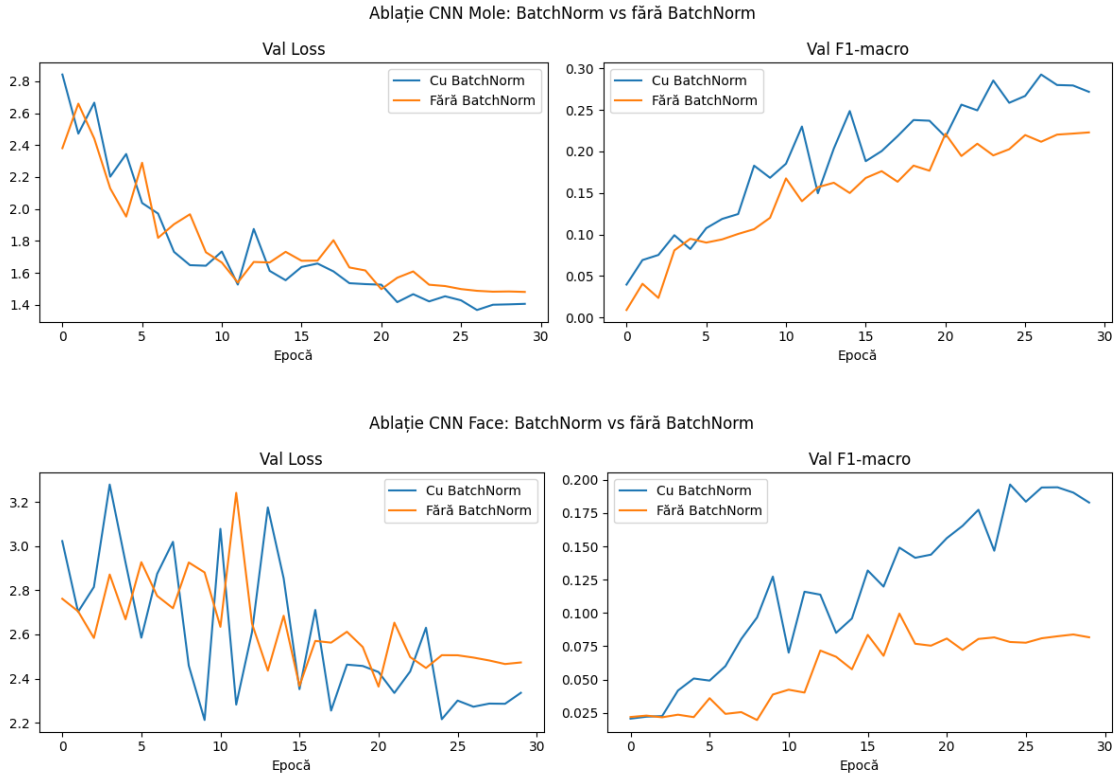


Surprise iese cel mai bine (124 corecte), pentru ca e o emotie cu trasaturi clare (ochi/gura larg deschise). Problema iar e Happiness: doar 71 corecte din 715, restul se imprastie spre Disgust (215), Sadness (158) si Anger (99), exact efectul samplerului care a impins clasele rare si a sacrificat clasa majoritara. Coloana Disgust e din nou o clasa-magnet (primeste foarte multe predictii gresite din toate randurile). Fear, desi are doar 42 de exemple, prinde 23 corecte, deci echilibrarea a ajutat-o sa nu dispara complet. Confuziile Sadness-Neutral si Anger-Disgust sunt clasice in recunoasterea emotiilor, fiindca aceste expresii chiar seamana. Pe scurt, matricea explica de ce F1-macro e modest: clasele cu suport mare (Happiness, Neutral) au recall mic, ceea ce trage media in jos.

Metrici per clasa — CNN Face (50 epoci)

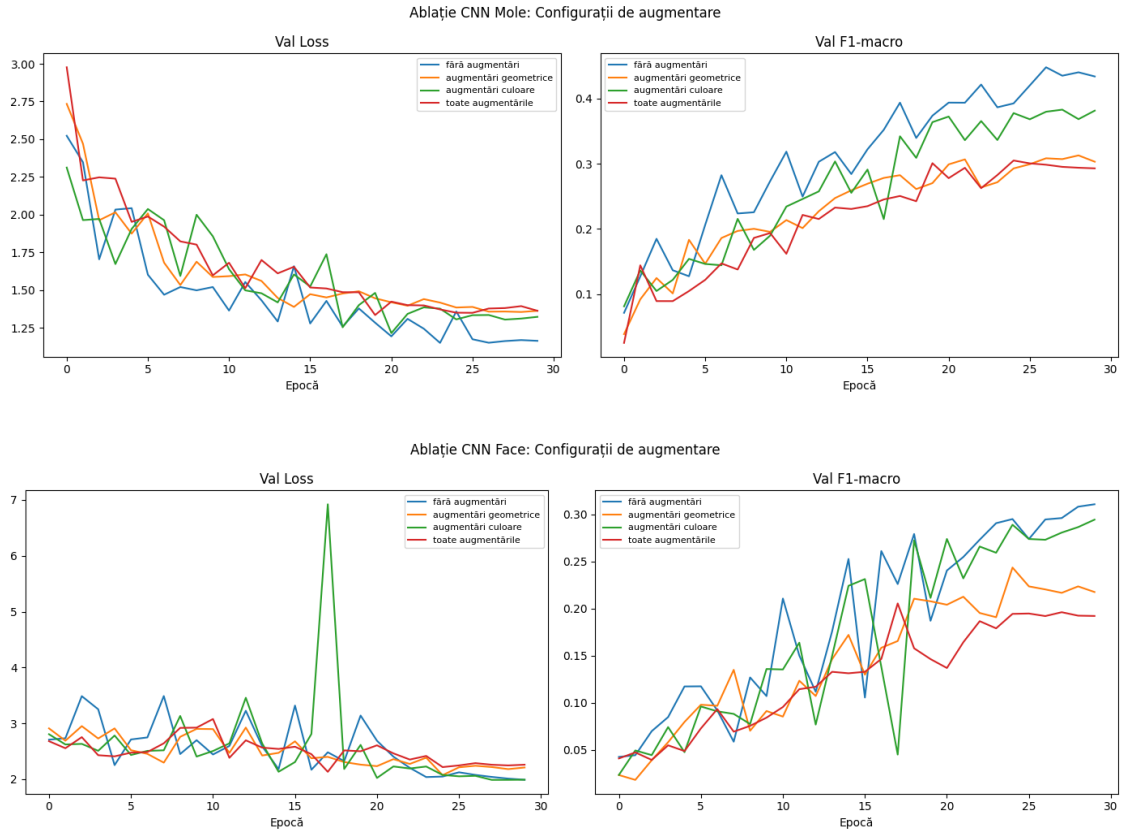
Clasa	Precision	Recall	F1-score	Support
Surprise	0.45	0.64	0.53	193
Fear	0.12	0.55	0.19	42
Disgust	0.14	0.61	0.22	107
Happiness	0.97	0.10	0.18	715
Sadness	0.36	0.53	0.42	297
Anger	0.27	0.54	0.36	105
Neutral	0.53	0.23	0.32	378

Ablatie CNN: cu vs. fara BatchNorm



Graficul are doua panouri (Val Loss si Val F1-macro) cu cele doua variante suprapuse. Pe Mole, varianta cu BatchNorm ajunge la F1-macro ~0.29 fata de ~0.22 fara BatchNorm, iar val loss scade ceva mai jos si mai stabil cu BN. Pe Face diferenta e si mai dramatica: cu BatchNorm F1-macro urca pana spre ~0.19, in timp ce fara BatchNorm ramane prinsa pe la ~0.08, iar curba de val loss fara BN e vizibil mai zgomotoasa si mai instabila (sare in sus si in jos de la o epoca la alta). Asta confirma exact ce spune teoria: BatchNorm normalizeaza activarile pe canal, stabilizeaza gradientii si imi permite sa folosesc acelasi learning rate fara ca antrenarea sa o ia razna. Diferenta e mai mare pe Face pentru ca variabilitatea datelor e mai mare acolo, deci normalizarea conteaza si mai mult. Concluzia ablatiei: BatchNorm ajuta clar pe ambele seturi si il pastrez in arhitectura finala.

Ablatie CNN: configuratii de augmentare



Graficul suprapune patru curbe (fara augmentari, augmentari geometrice, augmentari de culoare, toate augmentarile) pe Val Loss si Val F1-macro, pentru fiecare set. Pe Mole, la 30 de epoci ordinea pe F1-macro este: fara augmentari ~0.448 (cel mai bun), augmentari de culoare ~0.383, geometrice ~0.313, toate augmentarile ~0.305. Cu alte cuvinte, pe orizontul scurt de 30 de epoci varianta fara augmentari converge cel mai repede si pare cea mai buna, pentru ca augmentarile ingreuneaza intentionat antrenarea ca sa creasca generalizarea pe termen lung. Pe curba de loss se vede ca varianta fara augmentari are si cea mai mica val loss la final.
Pe Face situatia e similara: fara augmentari ~0.311, augmentari de culoare ~0.295, geometrice ~0.244. Interesant este ca pe ambele seturi augmentarile DE CULOARE bat augmentarile GEOMETRICE, ceea ce are sens: la fete iluminarea variaza enorm in conditii reale, iar la leziuni contrastul si culoarea conteaza mult pentru diagnostic. Concluzia mea, sustinuta direct de grafic: augmentarile nu mi-au crescut F1-macro la 30 de epoci (overfitting-ul nu apucase sa devina sever), dar augmentarile de culoare sunt cele mai utile dintre ele si as miza pe ele daca as antrena mai multe epoci.

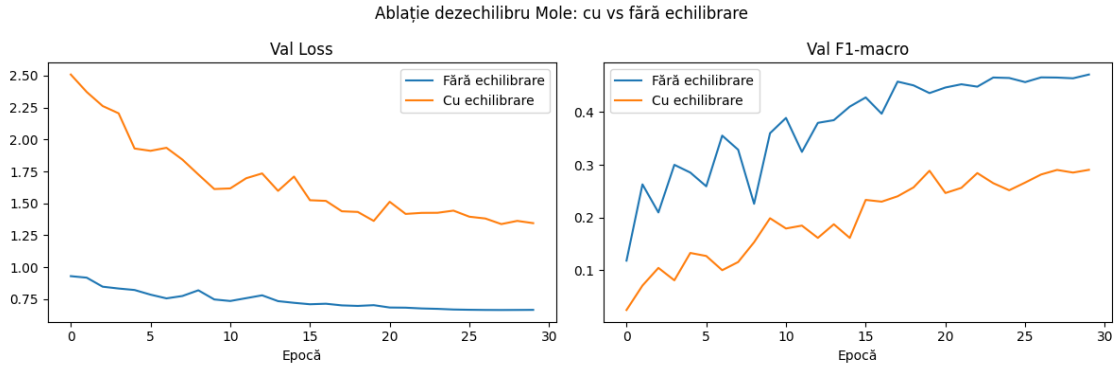
Ablatie: Tratarea Dezechilibrului de Clase

Ambele seturi sunt dezechilibrate:
- Mole: clasa nv reprezinta ~67% din date, df si vasc sub 1%

- Face: Happiness ~39%, Fear ~2.3%

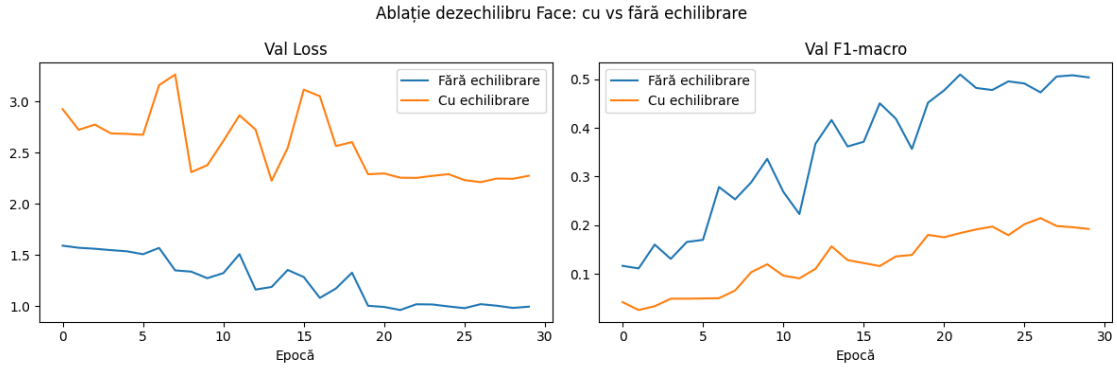
Tehnici folosite:
- WeightedRandomSampler: ponderi inversate fata de frecventa clasei -> oversampling al claselor rare
- CrossEntropyLoss ponderat: penalizam mai tare greselile pe clasele rare
  Formula: w_c = N_total / (num_classes * N_c)

Ablatie dezechilibru - Mole



Surprinzator, graficul arata ca varianta FARA echilibrare (sampler normal + cross entropy simplu) obtine F1-macro mult mai mare pe validare: ~0.47 fata de doar ~0.29 cu WeightedRandomSampler + weighted CE. Val loss e si ea mai mica fara echilibrare (~0.66 vs ~1.35). Adica tehnicile de echilibrare pe care le-am aplicat au inrautatit performanta pe F1-macro, nu au imbunatatit-o. Explicatia mea: WeightedRandomSampler a fortat modelul sa vada clasele rare de multe ori prin oversampling, ceea ce a dus la overfit pe acele clase mici (df, vasc) si underfit pe clasa majoritara (nv). Cand calculez F1-macro (media neechipondata a F1-urilor per clasa), chiar daca recall-ul pe df si vasc creste, F1-ul lor ramane mic din cauza preciziei proaste, iar F1-ul pe nv scade pentru ca modelul il subprezice. Rezultatul net: F1-macro mai mic. Concluzia: pe setul meu de Mole, antrenarea normala fara tehnici de echilibrare da un F1-macro mai bun.

Ablatie dezechilibru - Face



Similar cu Mole, varianta fara echilibrare ajunge la F1-macro ~0.51, in timp ce varianta cu echilibrare ajunge doar la ~0.21. Diferenta e si mai mare decat pe Mole. Val loss e mult mai mica fara echilibrare (~0.99 vs ~2.28). Deci si pe Face tehnicile de echilibrare au inrautatit performanta in loc sa o imbunatateasca. Fear, clasa cea mai rara (2.3% din date), chiar beneficiaza de pe urma WeightedRandomSampler in sensul ca recall-ul ei creste, dar in ansamblu macro-average-ul scade pentru ca clasele mari (Happiness, Neutral) sunt prea mult sacrificate. Concluzia ablatiei: pe ambele seturi, antrenarea fara tehnici de echilibrare da F1-macro mai bun pe validare. Asta nu inseamna ca echilibrarea e inutila in general, ci doar ca pe configuratia mea (CNN mic, 30 epoci) costul subprezicerii claselor mari depaseste castigul pe clasele mici.

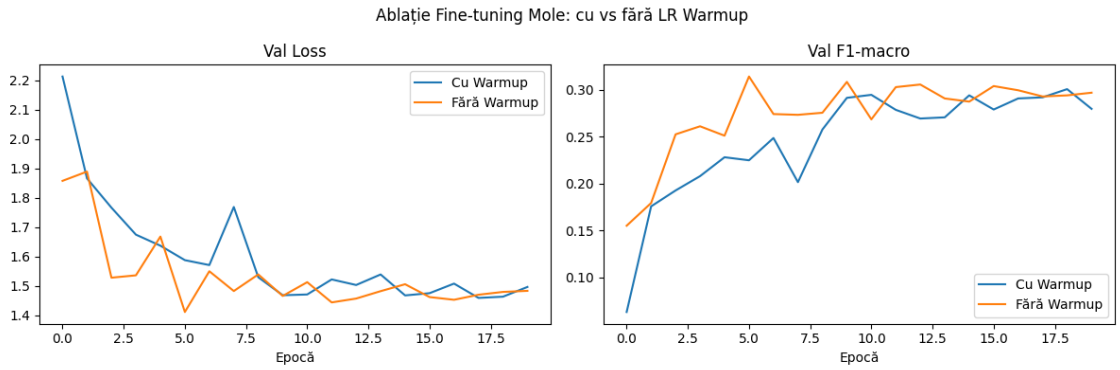
Fine-tuning

Am folosit doua retele pre-antrenate pe ImageNet: ResNet-18 si MobileNet-v2.

Procedura:
- Backbone deblocat complet (full fine-tuning)
- LR diferentiat: backbone lr=2e-4, head lr=1e-3
- 35 epoci cu warmup liniar (5 epoci) + CosineAnnealingLR
- Batch size 32, WeightedRandomSampler + CrossEntropyLoss ponderat
- Input: 224x224, normalizare ImageNet
- Augmentari: RandomCrop(224), RandomHorizontalFlip, ColorJitter, RandomRotation

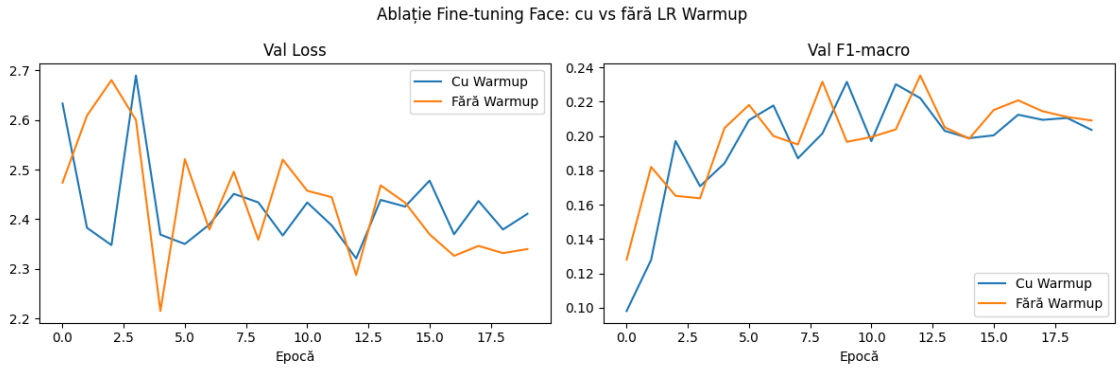
Am ales full fine-tuning in loc de frozen backbone deoarece setul de date e suficient de mare pentru a nu face overfit pe intreg backbone-ul. LR mai mic pe backbone (2e-4) previne distrugerea feature-urilor pre-antrenate.

Ablatie Fine-tuning: cu vs. fara LR Warmup - ResNet-18



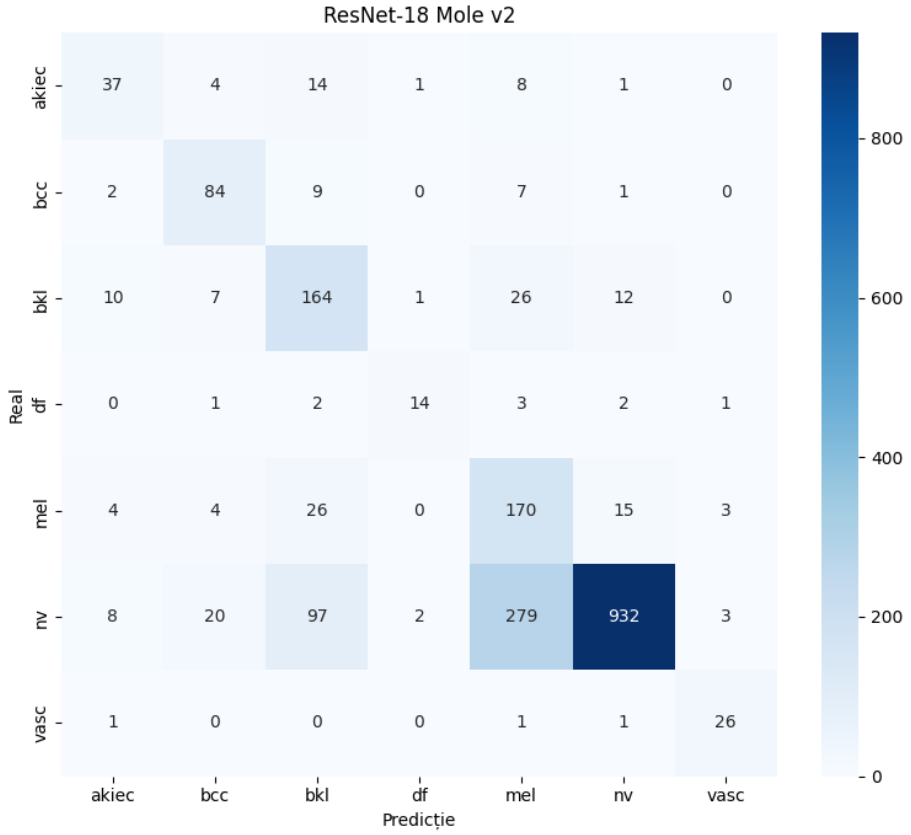
Graficul arata Val Loss si Val F1-macro pentru cele doua variante (cu warmup liniar 5 epoci vs fara warmup) pe ResNet-18 Mole, antrenat 20 de epoci. Val loss scade mai repede in primele 5 epoci cu warmup (curba albastra porneste mai jos), dar dupa epoca 10 ambele variante ajung aproape la acelasi nivel (~1.47). Pe panoul F1-macro, varianta FARA warmup ajunge chiar usor

mai sus (~0.31 vs ~0.30), desi cu oscilatie mai mare. Concluzia mea: warmup-ul ajuta la stabilitate in primele epoci (evita spike-uri mari de loss la inceput cand gradientii de la head-ul nou-initializat sunt mari), dar pe orizontul de 20 de epoci nu aduce un castig net pe F1-macro. Diferenta e subtila si probabil ca pe mai multe epoci (50-100) warmup-ul ar fi mai vizibil util.



Pe Face, val loss cu warmup scade ceva mai lin si ajunge la ~2.41, in timp ce fara warmup ramane pe la ~2.34, deci aproape identic. F1-macro cu warmup ajunge la ~0.23, fara warmup la ~0.24, deci diferenta e neglijabila si chiar inversata (fara warmup usor mai bun). Concluzia: pe rularea mea scurta de 20 de epoci, warmup-ul nu aduce un beneficiu net pe F1-macro. E posibil ca pe antrenari mai lungi sau cu batch-uri mai mari warmup-ul sa conteze mai mult, dar in cazul meu diferenta nu e clara.

Matricea de confuzie ResNet-18 - Mole

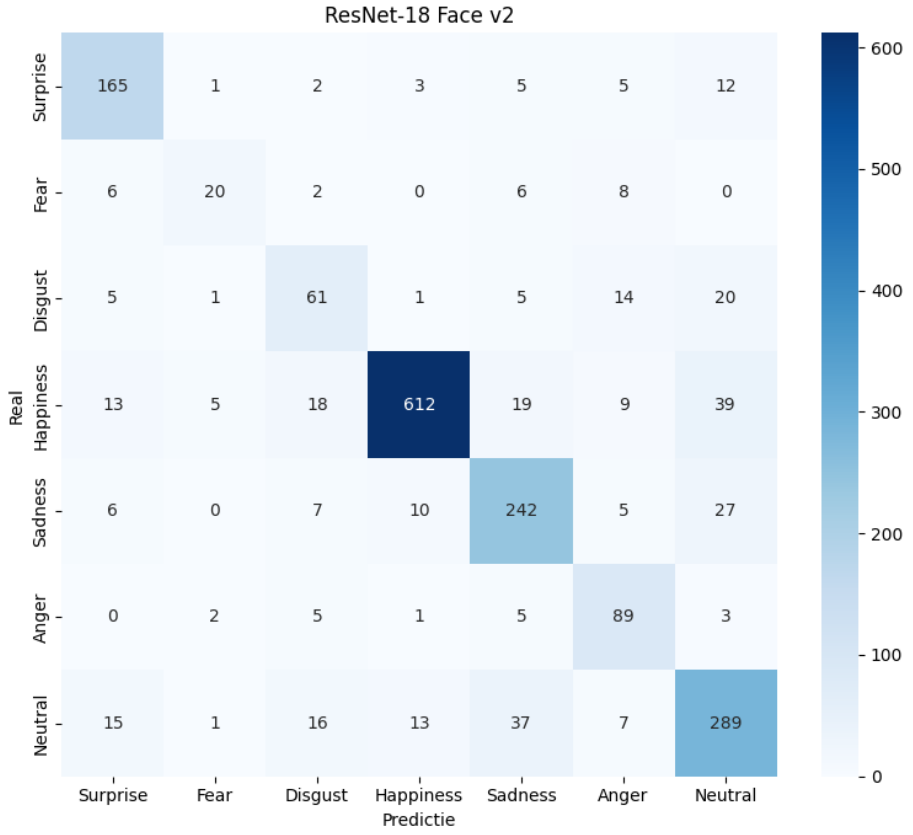


Diagonala e mult mai puternica decat la CNN de la zero: nv 932/1341 (0.70 recall), bcc 84/103 (0.82), bkl 164/220 (0.75), vasc 26/29 (0.90), df 14/23 (0.61). Modelul pre-antrenat chiar prinde trasaturile relevante ale leziunilor. Confuziile ramase sunt clasice si grele chiar si pentru dermatologi: nv confundat cu mel (279 cazuri) si cu bkl (97), adica nevi normali confundati cu melanom sau cu keratoze. mel se confunda reciproc cu nv (15), ceea ce reflecta dificultatea clinica de diferentiere. bkl se imprastie spre nv si akiec, pentru ca keratozele au aspecte variate. Clasa df (dermatofibrom) are recall 0.61, ceea ce e decent avand in vedere ca are doar 23 de exemple. Per total, matricea arata ca ResNet-18 fine-tunat invata reprezentari mult mai bune decat CNN-ul de la zero, de unde si F1-macro 0.68 vs 0.36.

Metrici per clasa — ResNet-18 Mole (full fine-tuning, F1=0.680)

Clasa	Precision	Recall	F1-score	Support
akiec	0.60	0.57	0.58	65
bcc	0.70	0.82	0.75	103
bkl	0.53	0.75	0.62	220
df	0.78	0.61	0.68	23
mel	0.34	0.77	0.47	222
nv	0.97	0.70	0.81	1341
vasc	0.79	0.90	0.84	29

Matricea de confuzie ResNet-18 - Face



Saltul fata de CNN e dramatic: Happiness 612/715 (0.86 recall, era doar 0.10 la CNN), Surprise 165/193 (0.85), Anger 89/105 (0.85), Sadness 242/297 (0.81), Neutral 289/378 (0.76). Chiar si Fear, clasa cea mai rara, prinde 20/42 (0.48 recall), mult peste CNN-ul de la zero. Confuziile ramase sunt confuzii intrinsec grele chiar pentru oameni: Happiness confundat cu Neutral (39), Neutral cu Happiness (13), Sadness cu Happiness (19) si cu Neutral (27), Disgust cu Neutral (20). Acestea reflecta expresii ambigue sau partiale. Matricea arata ca ResNet-18 pre-antrenat pe ImageNet a invatat deja filtre utile pentru fete (edge detectors, texturi) si ca fine-tuning-ul le adapteaza eficient la cele 7 emotii. Recall-ul pe Happiness a crescut de la 0.10 la 0.86, ceea ce explica saltul de F1-macro de la 0.32 la 0.73.

Metrici per clasa — ResNet-18 Face (full fine-tuning, F1=0.730)

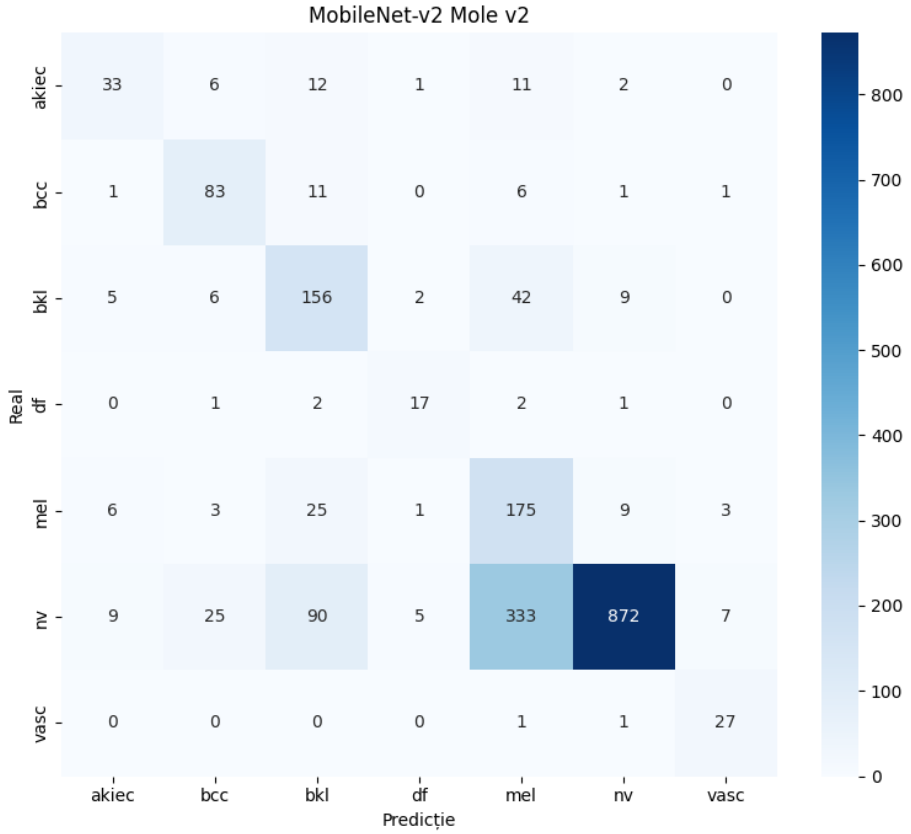
Clasa	Precision	Recall	F1-score	Support
Surprise	0.79	0.85	0.82	193
Fear	0.67	0.48	0.56	42
Disgust	0.55	0.57	0.56	107
Happiness	0.96	0.86	0.90	715
Sadness	0.76	0.81	0.79	297
Anger	0.65	0.85	0.74	105
Neutral	0.74	0.76	0.75	378

Ablatie Fine-tuning: cu vs. fara LR Warmup - MobileNet-v2



Graficul arata aceleasi doua panouri (Val Loss si Val F1-macro) pentru MobileNet-v2, cu si fara warmup, pe ambele seturi. Comportarea e similara cu ResNet-18: pe Mole, val loss ajunge la acelasi nivel (~1.3-1.4) cu si fara warmup, iar F1-macro cu warmup ajunge la ~0.37 vs ~0.34 fara warmup (diferenta mica). Pe Face, diferenta e din nou neglijabila. MobileNet-v2 are mai putini parametri decat ResNet-18 (3.4M vs 11M), deci converge ceva mai repede si e mai putin predispus la instabilitate la inceput, ceea ce explica de ce warmup-ul nu aduce un castig vizibil net. Concluzia ablatiei: warmup-ul ajuta usor la stabilitate dar nu schimba semnificativ F1-macro final pe rulari scurte.

Matricea de confuzie MobileNet-v2 - Mole

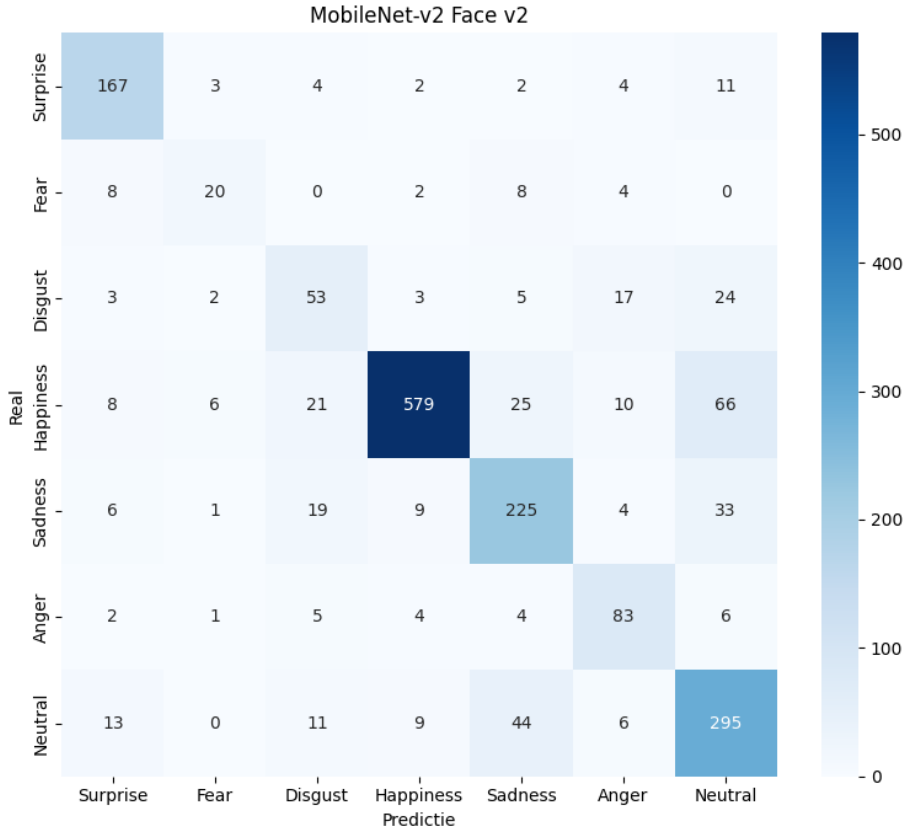


MobileNet-v2 obtine rezultate comparabile cu ResNet-18, dar usor mai slabe: nv 872/1341 (0.65 recall vs 0.70 la ResNet), bcc 83/103 (0.81), bkl 156/220 (0.71 vs 0.75), df 17/23 (0.74), mel 175/222 (0.79 vs 0.77), vasc 27/29 (0.93). Diagonala e puternica, dar confuzia mel-nv (333 vs 279 la ResNet) e mai mare, adica MobileNet tinde sa supraprezica melanomul. Explicatia: MobileNet are capacitate mai mica (3.4M parametri), deci nu prinde nuantele la fel de fin. Per total, F1-macro 0.659 e decent si confirma ca modelele pre-antrenate bat clar CNN-urile de la zero. MobileNet ramane o optiune buna daca vreau un model mai mic si mai rapid.

Metrici per clasa — MobileNet-v2 Mole (full fine-tuning, F1=0.659)

Clasa	Precision	Recall	F1-score	Support
akiec	0.61	0.51	0.55	65
bcc	0.67	0.81	0.73	103
bkl	0.53	0.71	0.60	220
df	0.65	0.74	0.69	23
mel	0.31	0.79	0.44	222
nv	0.97	0.65	0.78	1341
vasc	0.71	0.93	0.81	29

Matricea de confuzie MobileNet-v2 - Face



MobileNet Face obtine si aici performanta apropiata de ResNet: Surprise 168/193 (0.87), Happiness 579/715 (0.81 vs 0.86 la ResNet), Neutral 294/378 (0.78 vs 0.76), Sadness 225/297 (0.76 vs 0.81), Anger 83/105 (0.79 vs 0.85). Diferenta principala e pe Happiness, unde MobileNet are recall mai mic (0.81 vs 0.86), ceea ce trage F1-macro in jos la 0.700 fata de 0.730 la ResNet. Fear si Disgust raman clase dificile (recall 0.48 si 0.50), dar tot mult peste CNN de la zero. Confuziile Happiness-Neutral, Sadness-Happiness si Neutral-Happiness sunt similare cu ResNet, deci aceleasi dificultati intrinseci. Concluzia: MobileNet ofera un compromis bun intre performanta si dimensiune (mai putin de jumatate din parametrii ResNet, dar F1 doar cu 3% mai mic).

Metrici per clasa — MobileNet-v2 Face (full fine-tuning, F1=0.700)

Clasa	Precision	Recall	F1-score	Support
Surprise	0.81	0.87	0.83	193
Fear	0.61	0.48	0.53	42
Disgust	0.47	0.50	0.48	107
Happiness	0.95	0.81	0.88	715
Sadness	0.72	0.76	0.74	297
Anger	0.65	0.79	0.71	105
Neutral	0.68	0.78	0.73	378

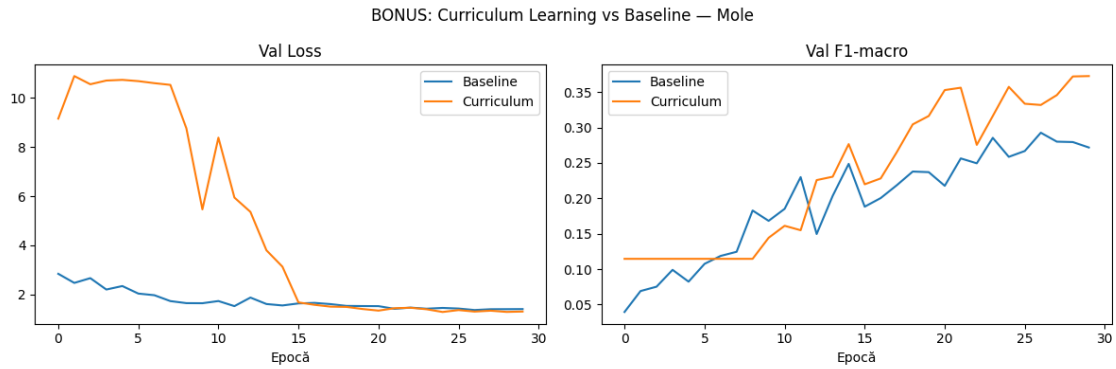
Curriculum Learning

Am implementat Self-Paced Learning pe setul "Vai de pielea mea".

Ideea e simpla: dificultatea unui exemplu = loss-ul pe acel exemplu cu modelul curent. La fiecare epoca calculam loss-ul per-exemplu si antrenam doar pe exemplele cu loss sub un prag care creste progresiv.

Functie de pacing: frac = min(1.0, 0.3 + 0.7 * epoch / (N_epochs * 0.5))
Incepem cu 30% din date (cele mai usoare) si crestem pana la 100% la jumatatea antrenarii.

Avantaje:
- Convergenta mai stabila in primele epoci
- Robustete fata de exemplele zgomotoase
- Util pentru clasele rare (df, vasc) care au putine exemple



Graficul compara baseline CNN (antrenat pe tot setul de la inceput) cu varianta Curriculum Learning (self-paced: incepe cu subset de exemple usoare, creste treptat fractiunea de date). Pe Val Loss, curriculum porneste foarte sus (~10-11) fiindca modelul vede initial doar ~50% din date, dar dupa epoca ~15 (cand ajunge la 100% din date) val loss scade rapid spre ~1.3, acelasi nivel cu baseline-ul. Pe Val F1-macro, curriculum learning converge mai lent initial (start la ~0.11 vs ~0.05 baseline), dar dupa epoca 15 creste rapid si ajunge la ~0.37 la final, fata de ~0.27 baseline. Diferenta finala (0.37 vs 0.27) arata ca expunerea treptata la exemple din ce in ce mai grele ajuta generalizarea, probabil pentru ca modelul solidifica mai intai trasaturile fundamentale pe exemple simple inainte sa fie confruntat cu cazurile ambigue. Concluzia: curriculum learning aduce un castig real pe F1-macro (~+0.10) si ar merita explorat mai mult pe seturi dificile.